Econometría III

David Giuliodori[1] Alejandro F. Rodriguez[2]

[1]Departamento de Economía
Universidad Nacional de Córdoba

[2]Departamento de Economía
Universidad Nacional de Córdoba

13 de octubre de 2025

Agenda

1. Introducción
2. Intervención y propagación dinámica
   - Modelo de retardos distribuidos
   - Modelo de función de transferencia
3. Modelos Multivariados: Modelos estructurales"Vector Autoregressive"- VAR(p)
4. Estimación del VAR: MCO vs. SUR

Estacionariedad y correlación cruzada

Considere una serie de tiempo k-dimensional, $\boldsymbol{X}_t = (X_{1t}, \ldots, X_{kt})$. La media y la varianza de este vector se definen como

$$\boldsymbol{\mu} = \mathbb{E}(\boldsymbol{X}_t), \quad \boldsymbol{\Gamma}_0 = \mathbb{E}\left[(\boldsymbol{X}_t - \boldsymbol{\mu})(\boldsymbol{X}_t - \boldsymbol{\mu})'\right]$$

donde la esperanza se toma elemento por elemento de la distribución conjunta de $\boldsymbol{X}_t$. Los elementos de la diagonal de $\boldsymbol{\Gamma}_0$ corresponden a las varianzas de cada componente de $\boldsymbol{X}_t$, y los elementos fuera de la diagonal corresponden a las covarianzas entre los elementos de $\boldsymbol{X}_t$.

Estacionariedad y correlación cruzada

Sea $\boldsymbol{D}$ una matriz diagonal de orden $k \times k$, cuyos elementos corresponden a las desviaciones estándar de los elementos de $\boldsymbol{X}_t$. De esta forma, la correlación cruzada contemporánea está definida por

$$\rho_0 = \boldsymbol{D}^{-1}\boldsymbol{\Gamma}_0\boldsymbol{D}^{-1}.$$

La matrix ρ_0 es simétrica y los elementos de la diagonal son unos. Para el caso de correlación en momentos no contemporáneos está definida por

$$\boldsymbol{\Gamma}_l = \mathbb{E}\left[(\boldsymbol{X}_t - \boldsymbol{\mu})(\boldsymbol{X}_{t-l} - \boldsymbol{\mu})'\right].$$

El elementos¡ (i, j) de la matriz $\boldsymbol{\Gamma}_l$ corresponde a la covarianza entre X_{it} y X_{jt-l}. Finalmente, la correlación cruzada de orden l está definida por

$$\rho_l = \boldsymbol{D}^{-1}\boldsymbol{\Gamma}_l\boldsymbol{D}^{-1}.$$

Correlación cruzada con rezago

Desde (4) podemos ver que

$$\rho_{ij}(l) = \frac{\mathbb{C}ov(X_{it}, X_{jt-l})}{\sigma_i \sigma_j}.$$

Cuando $l > 0$ este coeficiente mide la relación lineal entre X_{it} y X_{jt-l}, luego s $\rho_{ij}(l) \neq 0$ se puede concluir que la serie X_{jt-1} dirige la dinámica de X_{it} en el retardo l. En forma similar $\rho_{ji}(l) \neq 0$ se puede concluir que la serie X_{it-1} dirige la dinámica de X_{jt} en el retardo l. También, podemos observar que los elementos de la diagonal de la matrix $\boldsymbol{\rho}_l$ corresponden a la correlación de orden l de los elementos de $\boldsymbol{X}_t$. Finalmente, podemos concluir que las matrices $\boldsymbol{\Gamma}_l$ y $\boldsymbol{\rho}_l$ no son necesariamente simétricas.

Estimación Muestral

Dada las observaciones $\boldsymbol{X}_1, \ldots, \boldsymbol{X}_T$, la matriz de covarianza cruzada $\boldsymbol{\Gamma}_l$ puede estimarse por medio de

$$\widehat{\boldsymbol{\Gamma}}_l = \frac{1}{T} \sum_{t=l+1}^{T} (\boldsymbol{X}_t - \bar{\boldsymbol{X}})(\boldsymbol{X}_{t-l} - \bar{\boldsymbol{X}})', \text{ con } l \geq 0,$$

donde $\frac{1}{T}\sum_{t=1}^{T} \boldsymbol{X}_t$ es la media muestral vectorial. La correlación cruzada $\boldsymbol{\rho}_l$ estimada está dada por

$$\widehat{\boldsymbol{\rho}}_l = \widehat{\boldsymbol{D}}^{-1} \widehat{\boldsymbol{\Gamma}}_l \widehat{\boldsymbol{D}}^{-1}, \text{ con } l \geq 0,$$

donde $\widehat{\boldsymbol{D}}^{-1}$ es una matriz diagonal de orden $k \times k$ de las desviación estándar de los componentes $\boldsymbol{X}_t$. La estimación es consistente, pero es sesgada en muestras finitas.

Intervención con propagación AR(1)

Especificación básica

$$X_t = \alpha + \alpha_1 X_{t-1} + \beta_0 Y_t + \varepsilon_t, \qquad |\alpha_1| < 1$$

- Y_t: variable de intervención (p.ej., **step** único $Y_t = \mathbf{1}(t = T_0)$).
- β_0: **impacto contemporáneo** (corto plazo).
- α_1: dinámica propia de X_t que **propaga** el impacto en el tiempo.

Idea

Un cambio en Y_t mueve X_t hoy (*corto plazo*) y, vía α_1, deja una estela de efectos decrecientes (*mediano/largo plazo*).

Efectos de corto y largo plazo en AR(1)

Multiplicadores (respuesta a un step único unitario en Y_t)

$$\upsilon_0 = \beta_0, \quad \upsilon_1 = \alpha_1\beta_0, \quad \upsilon_2 = \alpha_1^2\beta_0, \ \ldots$$

- **Corto plazo (SR impact)**: $\upsilon_0 = \beta_0$.
- **Efecto acumulado hasta** h: $\sum_{j=0}^{h} \upsilon_j = \beta_0 \sum_{j=0}^{h} \alpha_1^j$.
- **Largo plazo (LR multiplier)**:

$$g = \sum_{j=0}^{\infty} \upsilon_j = \frac{\beta_0}{1-\alpha_1} \quad (|\alpha_1| < 1).$$

Lectura

$|\alpha_1|$ cerca de 1 $\Rightarrow$ convergencia lenta y persistencia alta.

Ejemplo numérico AR(1): step en $t = T_0$

Parámetros

$\alpha_1 = 0{,}6,\ \beta_0 = 2;$ step: $Y_t = 0$ si $t < T_0$, 1 si $t \geq T_0$.

Multiplicadores

$\upsilon_0 = 2,\ \upsilon_1 = 1{,}2,\ \upsilon_2 = 0{,}72,\ \upsilon_3 = 0{,}432.$

Acumulados

$\sum_{j=0}^{3} \upsilon_j = 4{,}352;\quad g = \frac{2}{1-0{,}6} = 5.$

Tabla (step unitario)

Periodo	Efecto en X
$t = T_0$	$+2{,}00$
$T_0 + 1$	$+1{,}20$
$T_0 + 2$	$+0{,}72$
$T_0 + 3$	$+0{,}432$
$\vdots$	$\downarrow$
∞	$\rightarrow 5{,}00$

Modelo de retardos distribuidos

Consideramos aquí modelos de la siguiente forma

$$\boldsymbol{\alpha}(L)X_t = \boldsymbol{\beta}(L)Y_t + \varepsilon_t,$$

donde $\boldsymbol{\alpha}(L) = 1 - \alpha_1 L - \cdots - \alpha_p L^r$ y $\boldsymbol{\beta}(L) = \beta_0 - \beta_1 L - \cdots - \beta_r L^h$. La ecuación también puede ser expresada así

$$X_t = \sum_{i=1}^{r} \alpha_i X_{t-i} + \sum_{j=0}^{h} \beta_j Y_{t-j} + \varepsilon_t.$$

Este modelo se llama $ARDL(r, h)$, donde ARDL son las siglas de Autoregressive Distributed Lag model (esto es modelo autorregresivo con retardos distribuidos).

Caso $h = 0$ y $\beta(L) = 0$

Si $h = 0$ y $\beta(L) = 0$ el modelo ARDL(r,h) se reduce a un modelo AR(r)

$$X_t = \sum_{i=1}^{r} \alpha_i X_{t-i} + \varepsilon_t.$$

Siempre que ε_t sea IID.

Caso $r = 0$ y $\beta_0 = 0$

En este caso tenemos un modelo de retardos distribuidos, es decir, un modelo DL(h)

$$X_t = \sum_{i=1}^{h} \beta_i Y_{t-i} + \varepsilon_t.$$

Función de transferencia

La estructura general del modelo de función de transferencia es

$$X_t = \frac{\beta_h(L)}{\alpha_r(L)} Y_t + \frac{\theta_q(L)}{\phi_p(L)} \varepsilon_t. \tag{1}$$

La relación dinámica entre X_t y cada una de la variable explicativa Y_t viene recogida por el cociente de polinomios

$$\frac{\beta_h(L)}{\alpha_r(L)} Y_t.$$

Además, las variables que puedan estar omitidas en el análisis pueden tener un efecto dinámico en X_t mediante el término residual

$$N_t = \frac{\theta_q(L)}{\phi_p(L)} \varepsilon_t.$$

Una forma alternativa de escribir (1) es como sigue

$$X_t = \upsilon_\infty(L) Y_t + \psi_\infty(L) \varepsilon_t = \frac{\beta_0 + \beta_1 L + \cdots + \beta_h L^h}{1 - \alpha_1 L - \cdots - \alpha_r L^r} Y_t + \frac{\theta_q(L)}{\phi_p(L)} \varepsilon_t.$$

Ejemplos

- Caso $h = 1, r = 0, q = 1, p = 0$

$$X_t = (\beta_0 + \beta_1 L) Y_t + (1 - \theta_1 L)\varepsilon_t.$$

- Caso $h = 0, r = 1, q = 1, p = 1$

$$X_t = \frac{1}{1 - \alpha_1 L} Y_t + \frac{1 - \theta_1 L}{1 - \phi_1 L}\varepsilon_t.$$

Función de respuesta

Los coeficientes $\upsilon_0, \upsilon_1, \cdots$ del polinomio $\boldsymbol{\upsilon}_\infty(L)$ se conocen como función de respuesta a un impulso.

Cuando las variables están expresadas en logaritmos, υ_0 es la elasticidad contemporánea y υ_k es la elasticidad de la variable X_t con respecto a la variable Y_t tras k periodos de desfase.

Los efectos de un impulso unitario sobre la variable endógena

Suponga que la serie está en un estado d equilibrio y que $\varepsilon_t = 0$. Caso $h = 1, r = 0, q = 1$

$$X_t = (\beta_0 + \beta_1 L) Y_t + (1 - \theta L)\varepsilon_t.$$
$$X_t^e = (\beta_0 + \beta_1 L) cte,$$

donde $cte = Y_t^e$

$$\begin{aligned}
X_{t^*} &= \beta_0(1 + cte) + \beta_1 cte = cte(\beta_0 + \beta_1) + \beta_0 \Rightarrow X_{t^*} - X_t^e = \beta_0. \\
X_{t^*+1} &= \beta_0 cte + \beta_1(1 + cte) = cte(\beta_0 + \beta_1) + \beta_1 \Rightarrow X_{t^*} - X_t^e = \beta_1. \\
X_{t^*+2} &= \beta_0 cte + \beta_1 cte = cte(\beta_0 + \beta_1) \Rightarrow X_{t^*} - X_t^e = 0.
\end{aligned}$$

La función respuesta será

$$v_k = \begin{cases} \beta_0 & k = 0 \\ \beta_1 & k = 1 \\ 0 & k \geq 2. \end{cases}$$

Caso $h = 1, r = 0$

$$X_t = (\beta_0 + \beta_1 L) Y_t + \varepsilon_t.$$

Supongamos que el valor de equilibrio de $Y_t^e = 0$ y, en consecuencia, el valor de equilibrio de $X_t^e = 0$ también es 0. $\upsilon_\infty(L) = (\beta_0 + \beta_1 L)$.

t	Y_t	υ_t	β_0	β_1	X_t^e
0	1	3	3	0.5	0
1	0	0.5			
2	0	0			
3	0	0			
4	0	0			
5	0	0			
6	0	0			
7	0	0			

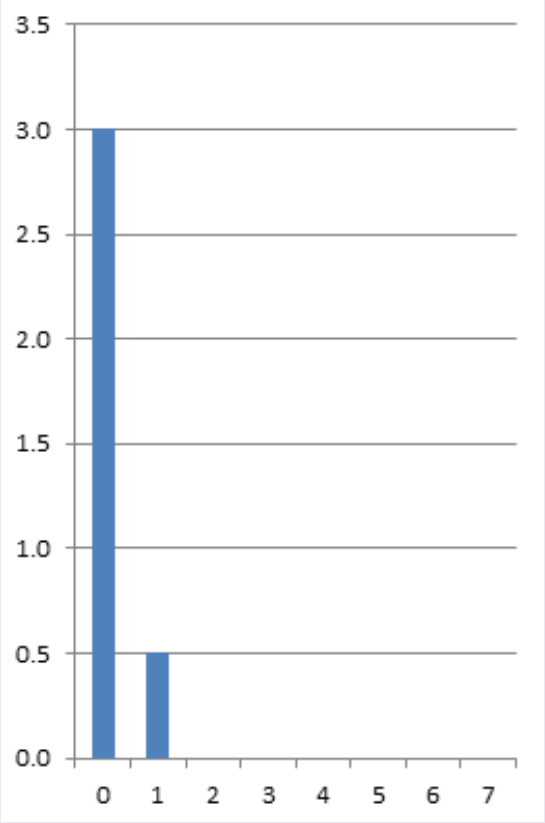

Caso $h = 4, r = 0$

$$X_t = (\beta_2 L^2 + \beta_3 L^3 + \beta_4 L^4) Y_t + \varepsilon_t.$$

El efecto puede durar mas periodos de tiempo y también aparecer después de un lapso de tiempo. $\upsilon_\infty(L) = (0{,}5L^2 + L^3 + 2L^4)$.

t	Y_t	υ_t	β_2	β_3	β_4	X_t^e
0	1	0	0.5	1	2	0
1	0	0				
2	0	0.5				
3	0	1				
4	0	2				
5	0	0				
6	0	0				
7	0	0				

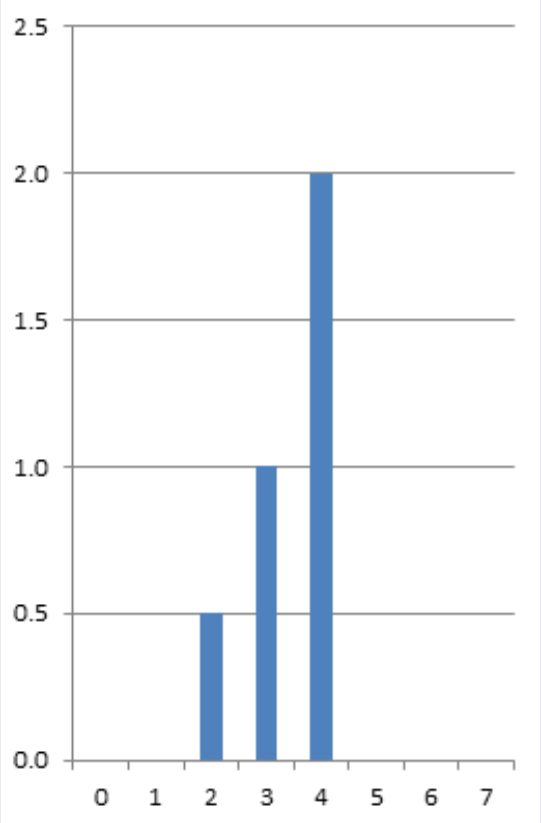

Derivación de los multiplicadores (I)

Caso $h = 0,\ r = 1$

$$X_t \;=\; \frac{\beta_0}{1-\alpha_1 L} Y_t \;+\; \frac{\theta_q(L)}{\phi_p(L)} \varepsilon_t.$$

Definimos los multiplicadores dinámicos como:

$$\frac{\beta_0}{1-\alpha_1 L} \;=\; \sum_{k=0}^{\infty} v_k L^k \;=\; v_0 + v_1 L + v_2 L^2 + \cdots \quad (|\alpha_1| < 1).$$

Multiplicamos por $(1-\alpha_1 L)$:

$$(1-\alpha_1 L)\Big(v_0 + v_1 L + v_2 L^2 + \cdots\Big) \;=\; \beta_0.$$

Derivación de los multiplicadores (II)

Expandiendo el producto:

$$v_0 + (v_1 - \alpha_1 v_0)L + (v_2 - \alpha_1 v_1)L^2 + (v_3 - \alpha_1 v_2)L^3 + \cdots = \beta_0 + 0 \cdot L + 0 \cdot L^2 + 0 \cdot L^3 + \cdots$$

Igualamos término a término:

$$\begin{aligned}
L^0: &\quad v_0 = \beta_0, \\
L^1: &\quad v_1 - \alpha_1 v_0 = 0 \quad \Rightarrow \quad v_1 = \alpha_1 v_0 = \alpha_1 \beta_0, \\
L^2: &\quad v_2 - \alpha_1 v_1 = 0 \quad \Rightarrow \quad v_2 = \alpha_1 v_1 = \alpha_1^2 \beta_0, \\
L^3: &\quad v_3 - \alpha_1 v_2 = 0 \quad \Rightarrow \quad v_3 = \alpha_1 v_2 = \alpha_1^3 \beta_0, \\
&\quad \vdots \\
L^k: &\quad v_k = \alpha_1 v_{k-1}.
\end{aligned}$$

Por inducción (con $v_0 = \beta_0$):

$$\boxed{v_k = \alpha_1^k \beta_0, \qquad k = 0, 1, 2, \ldots}$$

Caso $h = 0, r = 1$

$$\boldsymbol{v}_\infty(L) = \frac{\beta_0}{1 - \alpha_1 L} = \frac{3}{1 - 0{,}8L}.$$

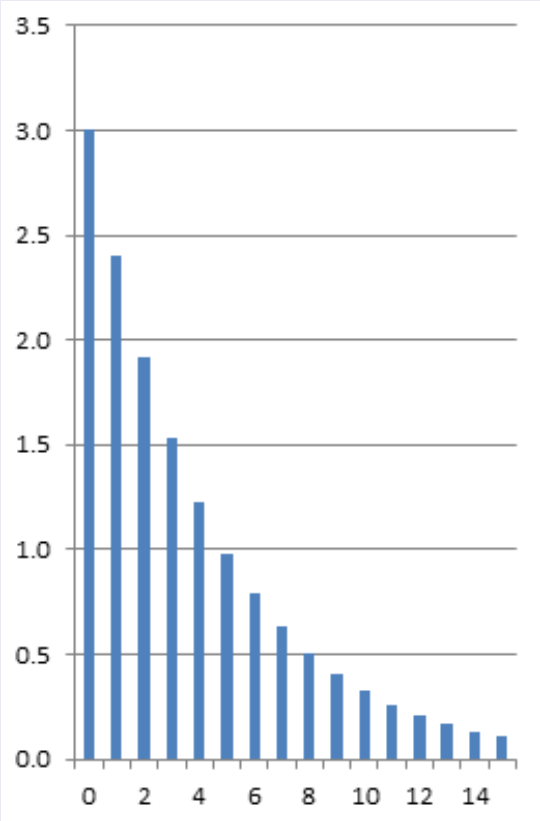

$$\boldsymbol{v}_\infty(L) = \frac{\beta_0}{1 - \alpha_1 L} = \frac{3}{1 - 0{,}4L}.$$

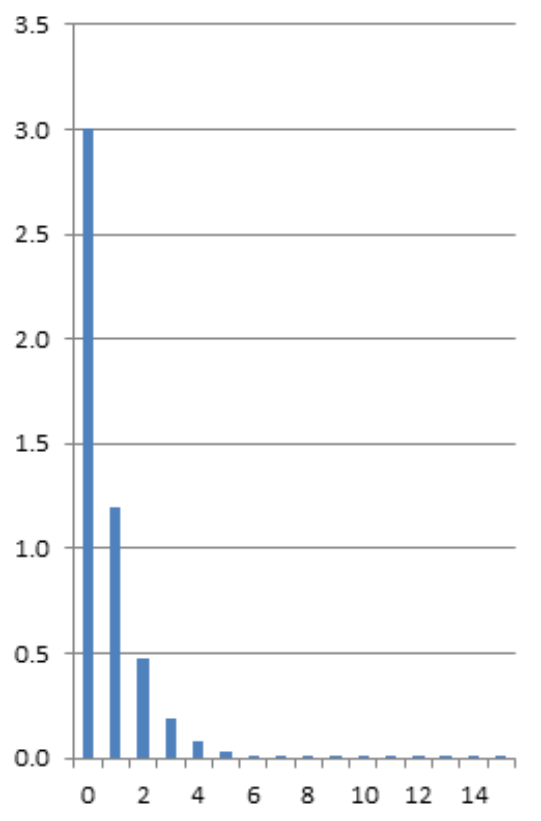

Caso: Resagos antes del primer efecto

$$v_\infty(L) = \frac{\beta_0 + \beta_1 L + \beta_2 L^2 + \beta_3 L^3}{1 - \alpha_1 L} = \frac{L^2 + 2L^3}{1 - 0{,}8L}.$$

Como antes puede haber lapsos de tiempo antes de que haya efectos y además podemos tener algunos periodos durante los cuales los efectos no sean sistemáticos.

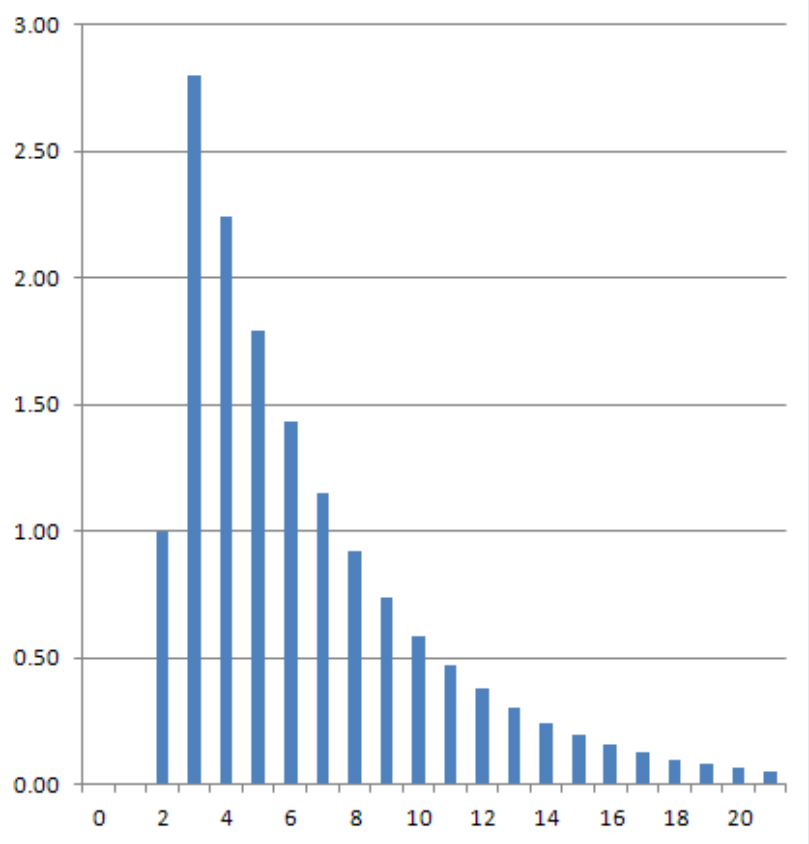

Efectos según la estructura de $\alpha_r(L)$

Si las raíces del polinomio $\alpha_r(L)$ están fuera del círculo unitario, variaciones transitorias de la variable explicativa no pueden tener efectos permanentes en la variable endógena.

El polinomio $\beta_h(L)$ alarga la estructura sin efectos sistemáticos mientras que el polinomio $\alpha_r(L)$ alarga dicha estructura imponiendo un determinado patrón de comportamiento.

Función de respuesta a un escalón (I)

Shock permanente en t^*

$$Y_t = \begin{cases} cte & t < t^* \\ cte + 1 & t \geq t^* \end{cases}$$

Antes del cambio ($t < t^*$), como $Y_t = cte$ en todos los rezagos:

$$X_t^e = \sum_{j=0}^{\infty} v_j \, cte = \left(v_0 + v_1 + v_2 + \cdots \right) cte.$$

Este es el nivel esperado de X_t en ausencia del shock.

Función de respuesta a un escalón (II)

Después del cambio, el efecto adicional se va acumulando:

$$
\begin{aligned}
X_{t^*} &= X_t^e + v_0, \\
X_{t^*+1} &= X_t^e + (v_0 + v_1), \\
X_{t^*+2} &= X_t^e + (v_0 + v_1 + v_2), \\
&\vdots \\
X_{t^*+k} &= X_t^e + \sum_{j=0}^{k} v_j.
\end{aligned}
$$

Definimos:

$$
V_k = \sum_{j=0}^{k} v_j \quad \Rightarrow \quad \boxed{X_{t^*+k} = X_t^e + V_k.}
$$

Interpretación: V_k mide el impacto acumulado del step hasta k períodos después del shock.

Función de respuesta a un escalón

$$X_{t^*} = \upsilon_0(cte + 1) + (\upsilon_1 + \upsilon_2 + \cdots)cte,$$

$$X_{t^*} - X_t^e = \upsilon_0 \Rightarrow V_0 = \upsilon_0.$$

$$X_{t^*+1} = (\upsilon_0 + \upsilon_1)(cte + 1) + (\upsilon_2 + \upsilon_1 + \cdots)cte,$$

$$X_{t^*+1} - X_t^e = \upsilon_0 + \upsilon_1 \Rightarrow V_1 = \upsilon_0 + \upsilon_1.$$

Para $k \geq 2$

$$V_k = \sum_{j=0}^{k} \upsilon_j.$$

A cada uno de estos coeficientes se les conoce con el nombre de multiplicadores y, si las variables están en logaritmos, pueden interpretarse como elasticidades acumuladas.
La ganancia o multiplicador de largo plazo viene dado por

$$g = V_\infty = \sum_{j=0}^{\infty} \upsilon_j = \frac{\beta_h(1)}{\alpha_r(1)}.$$

$$v_\infty(L) = (\beta_0 + \beta_1 L) = 3 + 0{,}5L.$$

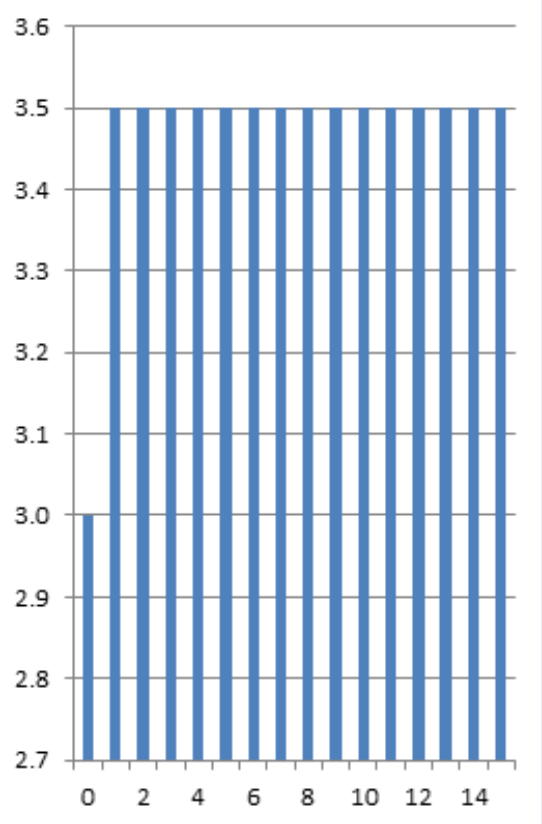

$$v_\infty(L) = (0{,}5L^2 + L^3 + 2L^4).$$

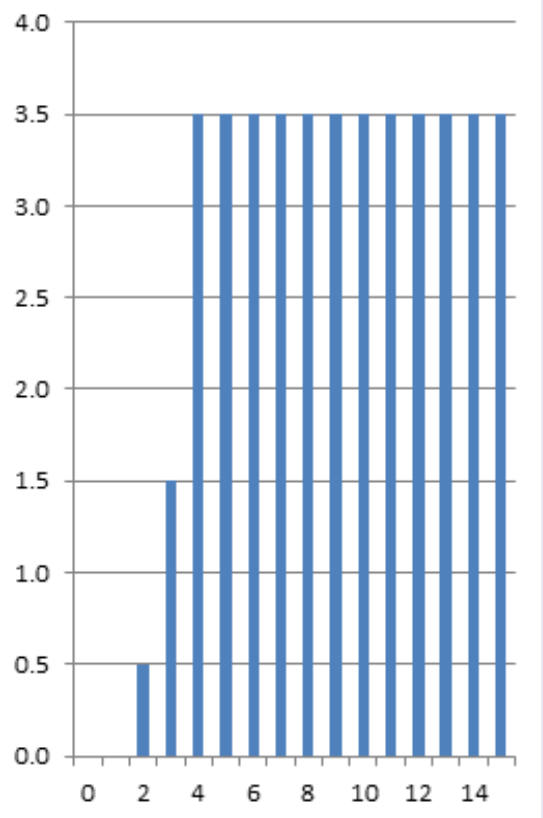

$$v_\infty(L) = \frac{\beta_0}{1-\alpha_1 L} = \frac{3}{1-0{,}8L}.$$

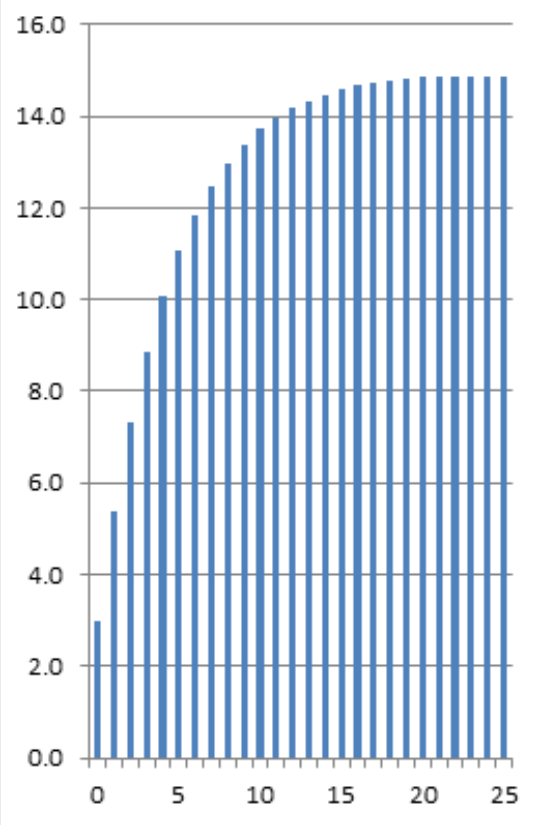

$$v_\infty(L) = \frac{\beta_0}{1-\alpha_1 L} = \frac{3}{1-0{,}4L}.$$

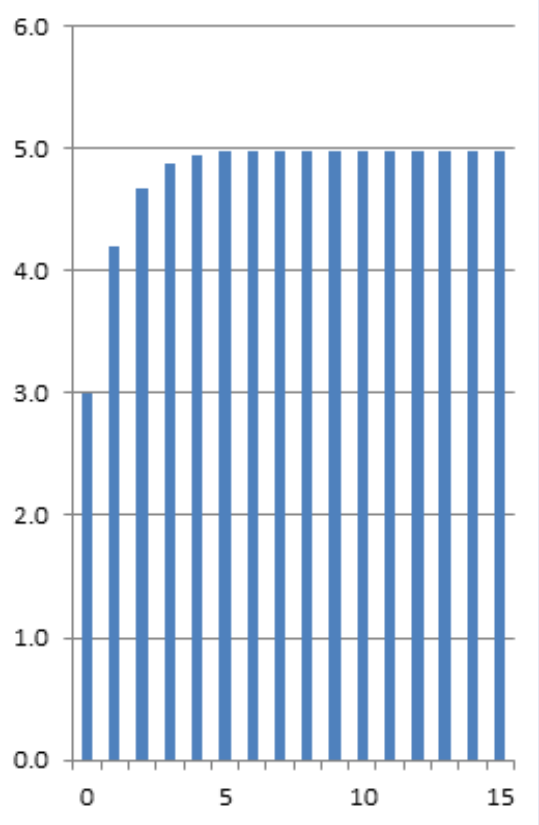

$$v_\infty(L) = \frac{\beta_0 + \beta_1 L + \beta_2 L^2 + \beta_3 L^3}{1 - \alpha_1 L} = \frac{L^2 + 2L^3}{1 - 0{,}8L}.$$

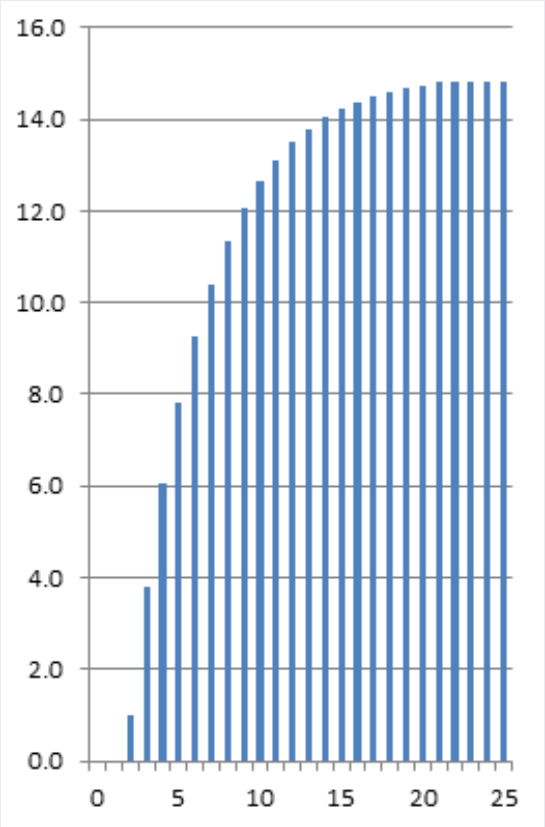

Generalización: Función de transferencia (ARX)

Forma general (una entrada)

$$\underbrace{\alpha(L)X_t}_{\text{AR en } X} = \alpha + \underbrace{\beta(L)Y_t}_{\text{impacto de } Y} + \varepsilon_t, \quad \alpha(L) = 1 - \alpha_1 L - \cdots - \alpha_r L^r, \ \beta(L) = \beta_0 + \cdots - \beta_h L^h$$

- **Función de transferencia**: $\dfrac{\beta(L)}{\alpha(L)}$.
- **Multiplicadores dinámicos** $\{\upsilon_j\}$ tales que

$$X_t = \alpha^\star + \sum_{j=0}^{\infty} \upsilon_j Y_{t-j} + \varepsilon_t^*, \text{ con } (1 - \alpha_1 L - \cdots - \alpha_r L^r)\upsilon_\infty(L) = \beta(L).$$

- **Largo plazo**:

$$g = \frac{\beta(1)}{\alpha(1)} \quad \text{si todas las raíces de } \alpha(L) = 0 \text{ están fuera del círculo unidad.}$$

Cómo obtener v_j: derivación algebraica

Conexión entre $\boldsymbol{v}_\infty(L)$, $\boldsymbol{\alpha}(L)$ y $\beta(L)$

Comparando ambas formas del modelo:

1. Por un lado:
$$\boldsymbol{\alpha}(L)X_t \;=\; \alpha + \beta(L)Y_t + \varepsilon_t.$$
2. Por otro, si
$$X_t = \alpha^\star + \boldsymbol{v}_\infty(L)Y_t + \varepsilon_t^*,$$
entonces
$$\boldsymbol{\alpha}(L)X_t = \boldsymbol{\alpha}(L)\boldsymbol{v}_\infty(L)Y_t + \boldsymbol{\alpha}(L)\varepsilon_t^*.$$

Conclusión: para que ambas representaciones sean consistentes,
$$\boldsymbol{\alpha}(L)\,\boldsymbol{v}_\infty(L) = \beta(L).$$

Cómo obtener v_j: derivación algebraica

Identidad de la función de transferencia

$$\boldsymbol{\alpha}(L)\,\boldsymbol{v}_\infty(L) = \boldsymbol{\beta}(L)$$

$$\boldsymbol{\alpha}(L) = 1 - \alpha_1 L - \cdots - \alpha_r L^r, \qquad \boldsymbol{\beta}(L) = \beta_0 + \beta_1 L + \cdots + \beta_h L^h.$$

Expansión en potencias de L

$$\left(1 - \alpha_1 L - \cdots - \alpha_r L^r\right)\left(v_0 + v_1 L + v_2 L^2 + \cdots\right) = \beta_0 + \beta_1 L + \beta_2 L^2 + \cdots + \beta_h L^h.$$

Igualando coeficientes (paso a paso)

término en L^0 : $\quad v_0 = \beta_0$

término en L^1 : $\quad v_1 - \alpha_1 v_0 = \beta_1 \;\Rightarrow\; v_1 = \beta_1 + \alpha_1 v_0$

término en L^2 : $\quad v_2 - \alpha_1 v_1 - \alpha_2 v_0 = \beta_2 \;\Rightarrow\; v_2 = \beta_2 + \alpha_1 v_1 + \alpha_2 v_0$

término en L^j : $\quad v_j - \alpha_1 v_{j-1} - \cdots - \alpha_r v_{j-r} = \beta_j$

$$\Rightarrow\; v_j = \beta_j + \alpha_1 v_{j-1} + \cdots + \alpha_r v_{j-r}, \qquad j \geq 3$$

Convenciones: $\beta_j = 0$ si $j > h$ y $v_k = 0$ si $k < 0$.

Recurrencia práctica y ejemplo numérico

Recurrencia general (resumen)

$$
\begin{aligned}
v_0 &= \beta_0, \\
v_1 &= \beta_1 + \alpha_1 v_0, \\
v_j &= \beta_j + \alpha_1 v_{j-1} + \cdots + \alpha_r v_{j-r}, \quad j \geq 2.
\end{aligned}
$$

Parámetros del ejemplo

$$
\boldsymbol{\beta}(L) = 1 + 0{,}5\, L, \qquad \boldsymbol{\alpha}(L) = 1 - 0{,}4\, L.
$$

Cálculo paso a paso de v_j

$$
\begin{aligned}
v_0 &= \beta_0 = 1, \\
v_1 &= \beta_1 + \alpha_1 v_0 = 0{,}5 + 0{,}4 \cdot 1 = 0{,}9, \\
v_2 &= \beta_2 + \alpha_1 v_1 = 0 + 0{,}4 \cdot 0{,}9 = 0{,}36, \\
v_3 &= \beta_3 + \alpha_1 v_2 = 0 + 0{,}4 \cdot 0{,}36 = 0{,}144.
\end{aligned}
$$

Multiplicador de largo plazo (LR)

$$
g = \frac{\boldsymbol{\beta}(1)}{\boldsymbol{\alpha}(1)} = \frac{1 + 0{,}5}{1 - 0{,}4} = \frac{1{,}5}{0{,}6} = 2{,}5.
$$

Estimación: función de transferencia (visión general)

Modelo con una entrada (ARX / Transferencia)

$$\alpha(L)\,X_t \;=\; \alpha \;+\; \beta(L)\,L^b\,Y_t \;+\; \varepsilon_t, \qquad \varepsilon_t \sim \text{ARMA/ARIMA},$$

donde $\alpha(L) = 1 - \alpha_1 L - \cdots - \alpha_r L^r$ y $\beta(L) = \beta_0 + \cdots + \beta_h L^h$.

Supuestos clave para Box–Jenkins

- Y_t es *exógena/predeterminada* respecto de ε_t (sin realimentación contemporánea).
- Si Y_t es **estocástica**, su autocorrelación debe retirarse (*pre-whitening*) para una identificación limpia.
- Si Y_t es **determinística** (step, pulse, ramp), no se hace pre-whitening: se estima como regresor exógeno con errores ARMA.

Paso 1: Pre-whitening de Y_t (si es estocástica)

Idea

Eliminar la autocorrelación propia de Y_t para que la función de correlación cruzada (CCF) con X_t refleje sólo la *transferencia* $Y \to X$.

Procedimiento

1. Modelar Y_t con ARIMA(p_z, d_z, q_z):

$$\phi_z(L)(1-L)^{d_z}\, Y_t \;=\; \theta_z(L)\, a_t, \quad a_t \sim \text{r.b.}$$

2. Definir el filtro estimado del paso 1:

$$\widehat{\mathcal{F}}_Y(L) \;=\; \frac{\widehat{\phi}_z(L)}{\widehat{\theta}_z(L)}(1-L)^{d_z}.$$

3. Filtrar ambas series con el **mismo** filtro:

$$w_t \equiv \widehat{\mathcal{F}}_Y(L)\, Y_t \approx \text{i.i.d.}, \qquad X_t^* \equiv \widehat{\mathcal{F}}_Y(L)\, X_t.$$

Por qué filtrar X_t también

Garantiza que cualquier correlación entre X_t^* y w_t provenga de la transferencia y no de la estructura ARMA de Y_t.

Paso 2: Identificación con CCF filtrada

CCF filtrada

$$\widehat{\rho}_{X^*w}(k) \;=\; \frac{\sum_t (X_t^* - \bar{X}^*)(w_{t-k} - \bar{w})}{\sqrt{\sum_t (X_t^* - \bar{X}^*)^2 \; \sum_t (w_{t-k} - \bar{w})^2}}.$$

Tras un buen pre-whitening, valores críticos aproximados: $\pm\frac{2}{\sqrt{T}}$.

Lectura de la CCF para identificar órdenes

- **Delay** b: primer retardo k con pico significativo ($k > 0$ si Y causa a X).
- **Numerador** n: cantidad y forma de picos *inmediatos* tras b.
- **Denominador** m: decaimiento geométrico/prolongado sugiere dinámica AR en la transferencia (raíces de $\alpha(L)$).

Consejo práctico

Primero fije b con la CCF; luego proponga (h, r) tentativos y afínelos con AIC/BIC y diagnóstico de residuos.

Pre-whitening: cómo actúa el filtro sobre X_t

Filtro aplicado en Python

$$X_t^\star = \frac{\widehat{\phi}(L)}{\widehat{\theta}(L)} X_t \iff$$ `X_star = lfilter(phi_hat_poly, theta_hat_poly, X)`

Ecuación que resuelve `lfilter(b,a,x)`

$$a_0 X_t^\star + a_1 X_{t-1}^\star + \cdots + a_q X_{t-q}^\star = b_0 X_t + b_1 X_{t-1} + \cdots + b_p X_{t-p}, \qquad (a_0 = 1).$$

Caso ARMA(1,1) estimado para Y_t

$$Y_t - \hat{\phi}\, Y_{t-1} = \varepsilon_t + \hat{\theta}\, \varepsilon_{t-1} \implies \widehat{\phi}(L) = 1 - \hat{\phi} L, \quad \widehat{\theta}(L) = 1 + \hat{\theta} L.$$

En `statsmodels`:

$$\texttt{phi_hat_poly} = [1, -\hat{\phi}], \qquad \texttt{theta_hat_poly} = [1, \hat{\theta}].$$

Aplicado a X_t:

$$X_t^\star = \frac{1 - \hat{\phi} L}{1 - \hat{\theta} L} X_t \therefore X_t^\star + \hat{\theta}\, X_{t-1}^\star = X_t - \hat{\phi}\, X_{t-1} \iff X_t^\star = (X_t - \hat{\phi}\, X_{t-1}) - \hat{\theta}\, X_{t-1}^\star.$$

Clave: la *parte MA* en Y_t introduce la dependencia recursiva en $X_{t-1}^\star$ al filtrar.
(Por defecto, `lfilter` usa condiciones iniciales cero, por eso $X_{-1}^\star = 0$.)

Ejemplo numérico: filtro ARMA(1,1) aplicado a X_t

Parámetros y datos

$$\hat{\phi} = 0{,}5, \qquad \hat{\theta} = 0{,}4, \qquad X = \{1,\ 2,\ 3,\ 4,\ 5\}.$$

Filtro:

$$\widehat{F_Y}(L) = \frac{1 - 0{,}5L}{1 + 0{,}4L} \implies X_t^\star + 0{,}4\, X_{t-1}^\star = X_t - 0{,}5\, X_{t-1}.$$

Cálculo recursivo (condiciones iniciales cero)

$$t = 0 : X_0^\star = 1{,}0.$$

$$t = 1 : X_1^\star = (2 - 0{,}5 \cdot 1) - 0{,}4\, X_0^\star = 1{,}5 - 0{,}4(1{,}0) = 1{,}1.$$

$$t = 2 : X_2^\star = (3 - 0{,}5 \cdot 2) - 0{,}4\, X_1^\star = 2{,}0 - 0{,}4(1{,}1) = 1{,}56.$$

$$t = 3 : X_3^\star = (4 - 0{,}5 \cdot 3) - 0{,}4\, X_2^\star = 2{,}5 - 0{,}4(1{,}56) = 1{,}876.$$

$$\vdots$$

Intuición

El numerador $(1 - 0{,}5L)$ "resta pasado" de X_t (componente AR); el denominador $(1 + 0{,}4L)$ introduce la **recursión** en $X^\star$ (componente MA). Así, Y_t queda "blanqueada" y X_t queda transformada de la misma forma, limpiando la autocorrelación propia de Y_t antes de mirar la CCF.

Paso 3: Estimación conjunta (MLE) y algoritmos

Modelo a estimar

$$\alpha(L)\,X_t \;=\; \alpha \;+\; \beta(L)\,L^b Y_t \;+\; \varepsilon_t, \qquad \varepsilon_t \sim \text{ARMA}(p,q).$$

Parámetros: $\{\alpha_i\}_{i=1}^{r}$, $\{\beta_j\}_{j=0}^{r}$, b, α y los de ε_t.

Inicialización y optimización

- **Valores iniciales**:
  - β_j a partir de una regresión MCO de X_t sobre $\{L^b Y_t, \ldots, L^{b+n} Y_t\}$ (con HAC si fuese necesario).
  - α_i y ARMA de ε_t: desde ACF/PACF del residuo preliminar.
- **Estimación**: máxima verosimilitud (Kalman/innovations) imponiendo raíces de $\alpha(L)$ fuera del círculo unidad e invertibilidad.
- **Selección de órdenes**: comparar (b, h, r, p, q) por AIC/BIC y parsimonia.

Paso 4: Diagnóstico y validación

Residuos e innovaciones

- **En original (informativo)**: Ljung–Box en residuos; ACF/PACF; normalidad (Jarque–Bera). Si hay leves desvíos, usar inferencia robusta (HAC).
- **Estabilidad**: raíces de $\phi(L)$ fuera del círculo unidad; *si* hay MA en el error, chequear invertibilidad de $\theta(L)$.
- **Diagnóstico clave BJ (espacio filtrado)**:
  - Pre-blanquear el input Y_t usando el filtro $\widehat{\mathcal{F}}_Y(L)$, y calcular $X_t^* = \widehat{\mathcal{F}}_Y(L)X_t$.
  - Calcular los residuos $\hat{e}_t$ del modelo ADL final estimado.
  - **Exigir** $\widehat{\rho}_{\hat{e},\,X^*}(k)$ **no significativa para** $k \geq 0$. (Usar bandas $\pm 1{,}96/\sqrt{T}$ y recorte de warm-up del filtro.)

Paso 5: Impacto de corto y largo plazo (SR/LR)

Definiciones

$$\mathrm{SR} = \upsilon_0 = \beta_0, \qquad g = \sum_{j=0}^{\infty} \upsilon_j \;=\; \frac{\boldsymbol{\beta}(1)}{\boldsymbol{\alpha}(1)} = \frac{\sum_{j=0}^{h} \beta_j}{1 - \sum_{i=1}^{r} \alpha_i}, \quad \text{si } |\text{raíces de } \boldsymbol{\alpha}| > 1.$$

Intervalos de confianza por Delta method

Sea $\theta = (\beta_0, \ldots, \beta_h, \alpha_1, \ldots, \alpha_r)^\top$ y $g(\theta)$ la ganancia.

$$\widehat{\mathrm{Var}}\big(g(\theta)\big) \;\approx\; \nabla g(\hat{\theta})^\top \, \widehat{\mathrm{Var}}(\hat{\theta}) \, \nabla g(\hat{\theta}),$$

donde

$$\frac{\partial g}{\partial \beta_j} = \frac{1}{\boldsymbol{\alpha}(1)}, \quad \frac{\partial g}{\partial \alpha_i} = \frac{\boldsymbol{\beta}(1)}{\big(\boldsymbol{\alpha}(1)\big)^2}.$$

Construir IC normales: $\hat{g} \pm z_{1-\alpha/2} \sqrt{\widehat{\mathrm{Var}}(g)}$.

Caso especial: Y_t determinística (intervención)

Qué cambia

- Si Y_t es **step/pulse/ramp** determinístico: no hay pre-whitening.
- Identificar primero $\alpha(L)$ y ε_t (ARIMA) en X_t; luego incluir Y_t y estimar $\beta(L)$ y b.

Ventaja

La inferencia sobre SR/LR suele ser más precisa (no hay error de medición en Y_t).

Precaución

Mantener exogeneidad: evitar dummies que absorban quiebres de ε_t mal modelados; usar dummies de *anticipación* si el evento era previsible.

Modelos estructurales

Suponga el siguiente modelo para un sistema de dos variables

$$\begin{aligned} X_{1t} &= \beta_1 X_{2t} + \alpha_{11} X_{1t-1} + \alpha_{12} X_{2t-1} + u_{1t} \\ X_{2t} &= \beta_2 X_{1t} + \alpha_{21} X_{1t-1} + \alpha_{22} X_{2t-1} + u_{2t}, \end{aligned}$$

donde $u_{it}, \ i = 1, 2$, son procesos ruido blanco independientes.

Si intentamos estimar cada una de estas dos ecuaciones por MCO, los estimadores no serán consistentes dado que existe correlación entre los regresores y la perturbación, ya que

$$\mathbb{E}(X_{2t} u_{1t}) = \beta_2 \mathbb{E}(X_{2t} u_{1t}) = \beta_2 \mathbb{E}(u_{1t}^2),$$

si $\beta_2 \neq 0$.

Modelos estructurales

El problema surge por una falta de identificación de las relaciones contemporáneas.

Una alternativa para poder estimar es restringir de forma adecuada los parámetros del modelo

1. Imponer restricciones sugeridas por la Teoría.
2. Trabajar con modelos de series temporales (VAR)

Forma reducida

Para esta segunda opción vamos a considerar la siguiente expresión alternativa del modelo anterior

$$\begin{bmatrix} 1 & -\beta_1 \\ -\beta_2 & 1 \end{bmatrix} \begin{bmatrix} X_{1t} \\ X_{2t} \end{bmatrix} = \begin{bmatrix} \alpha_{11} & \alpha_{12} \\ \alpha_{21} & \alpha_{22} \end{bmatrix} \begin{bmatrix} X_{1t-1} \\ X_{2t-1} \end{bmatrix} + \begin{bmatrix} u_{1t} \\ u_{2t} \end{bmatrix}.$$

$$\begin{aligned} \mathbf{B}\boldsymbol{X}_t &= \mathbf{A}\boldsymbol{X}_{t-1} + \mathbf{U}_t \\ \boldsymbol{X}_t &= \mathbf{B}^{-1}\mathbf{A}\boldsymbol{X}_{t-1} + \mathbf{B}^{-1}\mathbf{U}_t \\ \boldsymbol{X}_t &= \boldsymbol{\Phi}\boldsymbol{X}_{t-1} + \varepsilon_t. \end{aligned}$$

Forma reducida

Vamos a ver como son las perturbaciones del nuevo modelo

$$\begin{bmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{bmatrix} = \begin{bmatrix} 1 & -\beta_1 \\ -\beta_2 & 1 \end{bmatrix}^{-1} \begin{bmatrix} u_{1t} \\ u_{2t} \end{bmatrix} = \frac{1}{1-\beta_1\beta_2} \begin{bmatrix} 1 & -\beta_1 \\ -\beta_2 & 1 \end{bmatrix} \begin{bmatrix} u_{1t} \\ u_{2t} \end{bmatrix},$$

$$\varepsilon_{1t} = \frac{1}{1-\beta_1\beta_2}(u_{1t} - \beta_1 u_{2t}),$$

$$\varepsilon_{2t} = \frac{1}{1-\beta_1\beta_2}(u_{2t} - \beta_2 u_{1t}).$$

La covarianza entre ε_{1t} y ε_{2t} sólo será cero si $\beta_1 = \beta_2 = 0$.

En este último modelo, la relación contemporánea aparece modelizada como covarianza entre las perturbaciones en lugar de aparecer explícitamente en el modelo. Se pierde la relación de causalidad.

Modelos "Vector Autoregressive"- VAR(p)

El modelo VAR(p) viene dado por

$$\boldsymbol{X}_t = C + \Phi_1 \boldsymbol{X}_{t-1} + \Phi_2 \boldsymbol{X}_{t-2} + \cdots + \Phi_p \boldsymbol{X}_{t-p} + \varepsilon_t, \tag{2}$$

donde

$$\mathbb{E}(\varepsilon_t) = \mathbf{0}$$

y

$$\mathbb{E}(\varepsilon_t \varepsilon_t') = \Omega$$

y Ω es una matriz simétrica definida positiva.

Ejemplo VAR(1)

Modelo VAR(1) para un sistema bivariante

$$\begin{bmatrix} X_{1t} \\ X_{2t} \end{bmatrix} = \begin{bmatrix} \phi_{11} & \phi_{12} \\ \phi_{21} & \phi_{22} \end{bmatrix} \begin{bmatrix} X_{1t-1} \\ X_{2t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{bmatrix}.$$

Cada variable aparece regresada en su propio pasado y en el pasado de las demás variables. Todas las regresiones tienen las mismas variables explicativas.

$$\begin{aligned} X_{1t} &= \phi_{11}X_{1t-1} + \phi_{12}X_{2t-1} + \varepsilon_{1t} \\ X_{2t} &= \phi_{21}X_{1t-1} + \phi_{22}X_{2t-1} + \varepsilon_{2t}. \end{aligned}$$

En un modelo VAR las relaciones contemporáneas entre las variables del sistema se recogen en la matriz Ω. Dichas relaciones no representan relaciones de causalidad.

$$\Omega = \begin{bmatrix} \sigma_1^2 & \sigma_{12}^2 \\ \sigma_{12}^2 & \sigma_2^2 \end{bmatrix}.$$

Cuando $\sigma_{12}^2 = 0$ no hay relaciones contemporáneas entre las variables X_{1t} y X_{2t}.

Representación con operador de rezagos

El modelo VAR(p) puede escribirse alternativamente como

$$(I - \Phi_1 L - \Phi_2 L^2 - \cdots - \Phi_p L^p)\boldsymbol{X}_t = C + \varepsilon_t.$$

El modelo es estacionario si las raíces de la ecuación $|I - \Phi_1 L - \Phi_1 L^2 - \cdots - \Phi_p L^p| = 0$ son estrictamente mayores que uno en módulo.

Ejemplo VAR(1)

Modelo VAR(1) para un sistema bivariante

$$\begin{bmatrix} X_{1t} \\ X_{2t} \end{bmatrix} = \begin{bmatrix} 0{,}5 & 0{,}2 \\ 0{,}8 & 0{,}3 \end{bmatrix} \begin{bmatrix} X_{1t-1} \\ X_{2t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{bmatrix}.$$

$$I - \Phi w = \begin{bmatrix} 1 - 0{,}5w & -0{,}2w \\ -0{,}8w & 1 - 0{,}3w \end{bmatrix}.$$

$$|I - \Phi w| = 1 - 0{,}8w - 0{,}01w^2.$$

$$1 - 0{,}8w - 0{,}01w^2 = 0 \Rightarrow w = \begin{cases} -81{,}23 \\ 1{,}23. \end{cases}$$

Estimación ecuación por ecuación (MCO)

MCO

- En un VAR(p) cada variable X_{it} se expresa como regresión sobre p rezagos de todas las variables.
- Podemos estimar **cada ecuación por separado** usando Mínimos Cuadrados Ordinarios (MCO).
- Supuestos: innovaciones con media cero, varianza finita y sin correlación serial en el tiempo.
- Si los errores de distintas ecuaciones están correlacionados en el mismo t, MCO sigue siendo:
  - **Consistente**: converge al valor verdadero cuando $T \to \infty$.
  - **No eficiente**: no aprovecha la correlación contemporánea entre ecuaciones.
- Alternativa: **SUR** = Seemingly Unrelated Regressions (Regresiones aparentemente no relacionadas).

¿Qué es el método SUR?

SUR = Seemingly Unrelated Regressions (Regresiones aparentemente no relacionadas).

- Sistema de M ecuaciones de regresión lineal.
- Cada ecuación tiene sus propios regresores.
- Los errores de distintas ecuaciones en el mismo período t pueden estar **correlacionados**.

Idea central

Aunque cada ecuación parece "separada", en realidad están **conectadas** a través de la **matriz de covarianza de los errores**.

Modelo SUR en forma matricial

El sistema SUR se compone de M ecuaciones lineales, una por cada variable dependiente:

$$\begin{aligned} \mathbf{y}_1 &= Z_1\beta_1 + \mathbf{u}_1, \\ \mathbf{y}_2 &= Z_2\beta_2 + \mathbf{u}_2, \\ &\vdots \\ \mathbf{y}_M &= Z_M\beta_M + \mathbf{u}_M, \end{aligned} \qquad \text{con } \operatorname{Cov}(\mathbf{u}_t) = \Omega_u = \begin{bmatrix} \omega_{11} & \cdots & \omega_{1M} \\ \vdots & \ddots & \vdots \\ \omega_{M1} & \cdots & \omega_{MM} \end{bmatrix}.$$

Donde los $\omega_{ij} = \omega_{ij}$, para todo $i \neq j$.

Modelo SUR en forma matricial

El sistema SUR se compone de M ecuaciones lineales, una por cada variable dependiente:

$$\begin{aligned}
\mathbf{y}_1 &= Z_1\beta_1 + \mathbf{u}_1, \\
\mathbf{y}_2 &= Z_2\beta_2 + \mathbf{u}_2, \\
&\vdots \\
\mathbf{y}_M &= Z_M\beta_M + \mathbf{u}_M,
\end{aligned}
\qquad \text{con } \operatorname{Cov}(\mathbf{u}_t) = \Omega_u = \begin{bmatrix} \omega_{11} & \cdots & \omega_{1M} \\ \vdots & \ddots & \vdots \\ \omega_{M1} & \cdots & \omega_{MM} \end{bmatrix}.$$

Donde los $\omega_{ij} = \omega_{ij}$, para todo $i \neq j$.

En forma apilada:

$$\underbrace{\begin{bmatrix} \mathbf{y}_1 \\ \mathbf{y}_2 \\ \vdots \\ \mathbf{y}_M \end{bmatrix}}_{\mathbf{X}^* \ (MT\times 1)} = \underbrace{\begin{bmatrix} Z_1 & 0 & \cdots & 0 \\ 0 & Z_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & Z_M \end{bmatrix}}_{\mathbf{Z}^* \ (MT\times K)} \underbrace{\begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_M \end{bmatrix}}_{\beta \ (K\times 1)} + \underbrace{\begin{bmatrix} \mathbf{u}_1 \\ \mathbf{u}_2 \\ \vdots \\ \mathbf{u}_M \end{bmatrix}}_{\mathbf{u}^* \ (MT\times 1)}, \qquad \mathrm{Var}(\mathbf{u}^*) = \Sigma = I_T \otimes \Omega_u.$$

SUR aplicado al VAR

SUR

- En un VAR, todas las ecuaciones comparten los mismos regresores: rezagos de todas las variables endógenas.
- El sistema puede escribirse como:

$$\boldsymbol{X}^* = \boldsymbol{Z}^* \boldsymbol{\theta} + \boldsymbol{u}^*, \qquad \mathrm{Var}(\boldsymbol{u}^*) = \Sigma = I_T \otimes \Omega_u.$$

- Si Ω_u no es diagonal, hay correlación contemporánea entre ecuaciones.
- SUR estima usando esta correlación para ganar **eficiencia estadística**.

Fórmula del estimador SUR (GLS)

SUR

$$\hat{\theta}_{SUR} = \left(\mathbf{Z}^{*'}\Sigma^{-1}\mathbf{Z}^{*}\right)^{-1}\mathbf{Z}^{*'}\Sigma^{-1}\boldsymbol{X}^{*}, \qquad \Sigma = I_T \otimes \Omega_u$$

- Si $\Omega_u = \sigma^2 I$, SUR coincide con MCO.
- Como Ω_u es desconocida, se aplica un **FGLS**:
  - Paso 1: Estimar por MCO y obtener residuales.
  - Paso 2: Calcular $\hat{\Omega}_u$ y reestimar por GLS.

SUR aplicado al VAR: ejemplo 2×2

Ejemplo

Consideremos un VAR(1) con dos variables X_{1t} y X_{2t}:

$$\begin{cases} X_{1t} = \phi_{10} + \phi_{11} X_{1,t-1} + \phi_{12} X_{2,t-1} + u_{1t}, \\ X_{2t} = \phi_{20} + \phi_{21} X_{1,t-1} + \phi_{22} X_{2,t-1} + u_{2t}. \end{cases}$$

- Cada ecuación se puede estimar por separado con MCO.
- Si $\mathrm{Cov}(u_{1t}, u_{2t}) \neq 0$, hay **correlación contemporánea**.
- MCO sigue siendo consistente, pero puede ser no eficiente porque ignora esa correlación.

SUR (GLS) en el ejemplo VAR(1) bivariado

Sea un VAR(1) con T observaciones. Por el rezago, las observaciones efectivas son $T^* = T - 1$.

$$\underbrace{\begin{bmatrix} \boldsymbol{X}_1 \\ \boldsymbol{X}_2 \end{bmatrix}}_{\boldsymbol{X}^* \ (2T^* \times 1)} = \underbrace{\begin{bmatrix} \mathbf{1}_{T^*} & \boldsymbol{X}_{1,-1} & \boldsymbol{X}_{2,-1} & \mathbf{0} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \mathbf{1}_{T^*} & \boldsymbol{X}_{1,-1} & \boldsymbol{X}_{2,-1} \end{bmatrix}}_{\mathbf{Z}^* \ (2T^* \times 6)} \underbrace{\begin{bmatrix} \phi_{10} \\ \phi_{11} \\ \phi_{12} \\ \phi_{20} \\ \phi_{21} \\ \phi_{22} \end{bmatrix}}_{\boldsymbol{\phi} \ (6 \times 1)} + \underbrace{\begin{bmatrix} \boldsymbol{u}_1 \\ \boldsymbol{u}_2 \end{bmatrix}}_{\boldsymbol{u} \ (2T^* \times 1)} .$$

$$\mathrm{Var}(\boldsymbol{u}) = \Sigma = I_{T^*} \otimes \Omega_u, \qquad \Omega_u = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{12} & \sigma_{22} \end{bmatrix} \quad (2 \times 2).$$

- $\boldsymbol{X}_1 = [X_{12}, \ldots, X_{1T}]'$ y $\boldsymbol{X}_2 = [X_{22}, \ldots, X_{2T}]'$ son vectores $(T^* \times 1)$ de las series *sin* rezago (toma $t = 2, \ldots, T$).
- $\boldsymbol{X}_{1,-1} = [X_{11}, \ldots, X_{1,T-1}]'$ y $\boldsymbol{X}_{2,-1} = [X_{21}, \ldots, X_{2,T-1}]'$ son los rezagos $(T^* \times 1)$ (toma $t - 1 = 1, \ldots, T - 1$).
- $\mathbf{1}_{T^*}$ es un vector de unos $(T^* \times 1)$ (constante en cada ecuación).
- $\mathbf{Z}^*$ es de dimensión $(2T^* \times 6)$: 2 ecuaciones $\times$ (constante + 2 regresores rezagados) = 6 parámetros.

El estimador SUR (GLS) es:

$$\hat{\phi}_{\text{SUR}} = (\boldsymbol{Z}^{*\prime} \Sigma^{-1} \boldsymbol{Z}^*)^{-1} \boldsymbol{Z}^{*\prime} \Sigma^{-1} \boldsymbol{X}^*.$$

Observación clave. En este VAR(1) ambas ecuaciones usan *exactamente* el mismo conjunto de regresores $\left(\mathbf{1}_{T^*}, \boldsymbol{X}_{1,-1}, \boldsymbol{X}_{2,-1}\right)$. Por lo tanto, bajo homocedasticidad y ausencia de autocorrelación serial en $\boldsymbol{u}_t$, *no hay ganancia de eficiencia con SUR*: OLS por ecuación coincide con GLS.

El VAR(1) en Notación Matricial

Definición de Vectores y Matrices (para $T^* = T - 1$ observaciones)

Las dos ecuaciones del VAR(1) se pueden escribir como:

$$\underbrace{\begin{pmatrix} X_{12} \\ \vdots \\ X_{1T} \end{pmatrix}}_{\boldsymbol{x}_1} = \underbrace{\begin{pmatrix} 1 & X_{1,1} & X_{2,1} \\ \vdots & \vdots & \vdots \\ 1 & X_{1,T-1} & X_{2,T-1} \end{pmatrix}}_{\boldsymbol{Z}} \underbrace{\begin{pmatrix} \phi_{10} \\ \phi_{11} \\ \phi_{12} \end{pmatrix}}_{\boldsymbol{\phi}_1} + \underbrace{\begin{pmatrix} u_{12} \\ \vdots \\ u_{1T} \end{pmatrix}}_{\boldsymbol{u}_1}$$

$$\underbrace{\begin{pmatrix} X_{22} \\ \vdots \\ X_{2T} \end{pmatrix}}_{\boldsymbol{x}_2} = \underbrace{\begin{pmatrix} 1 & X_{1,1} & X_{2,1} \\ \vdots & \vdots & \vdots \\ 1 & X_{1,T-1} & X_{2,T-1} \end{pmatrix}}_{\boldsymbol{Z}} \underbrace{\begin{pmatrix} \phi_{20} \\ \phi_{21} \\ \phi_{22} \end{pmatrix}}_{\boldsymbol{\phi}_2} + \underbrace{\begin{pmatrix} u_{22} \\ \vdots \\ u_{2T} \end{pmatrix}}_{\boldsymbol{u}_2}$$

Observación Fundamental

La matriz de regresores $\boldsymbol{Z}$ (de dimensión $T^* \times 3$) es **idéntica** para ambas ecuaciones.

MCO Ecuación por Ecuación

Aplicando la fórmula matricial de MCO a cada ecuación por separado, obtenemos:

$$\widehat{\phi}_{1,MCO} = (\boldsymbol{Z}'\boldsymbol{Z})^{-1}\boldsymbol{Z}'\boldsymbol{X}_1$$
$$\widehat{\phi}_{2,MCO} = (\boldsymbol{Z}'\boldsymbol{Z})^{-1}\boldsymbol{Z}'\boldsymbol{X}_2$$

Podemos apilar estos dos estimadores en un único vector de parámetros:

$$\widehat{\phi}_{MCO} = \begin{pmatrix} \widehat{\phi}_{1,MCO} \\ \widehat{\phi}_{2,MCO} \end{pmatrix} = \begin{pmatrix} (\boldsymbol{Z}'\boldsymbol{Z})^{-1}\boldsymbol{Z}'\boldsymbol{X}_1 \\ (\boldsymbol{Z}'\boldsymbol{Z})^{-1}\boldsymbol{Z}'\boldsymbol{X}_2 \end{pmatrix}$$

El Sistema Apilado para SUR (MCG)

Construcción del Modelo General

Apilamos las dos ecuaciones en un único sistema:

$$\underbrace{\begin{pmatrix} \boldsymbol{X}_1 \\ \boldsymbol{X}_2 \end{pmatrix}}_{\boldsymbol{X}^*} = \underbrace{\begin{pmatrix} \boldsymbol{Z} & \boldsymbol{0} \\ \boldsymbol{0} & \boldsymbol{Z} \end{pmatrix}}_{\boldsymbol{Z}^*} \underbrace{\begin{pmatrix} \phi_1 \\ \phi_2 \end{pmatrix}}_{\phi} + \underbrace{\begin{pmatrix} \boldsymbol{u}_1 \\ \boldsymbol{u}_2 \end{pmatrix}}_{\boldsymbol{u}}$$

La matriz $\boldsymbol{Z}^*$ se puede escribir de forma compacta usando el producto de Kronecker:

$$\boldsymbol{Z}^* = I_2 \otimes \boldsymbol{Z}$$

donde I_2 es la matriz identidad de 2×2.

Matriz de Varianzas y Covarianzas del Error

La matriz de covarianzas del término de error apilado $\boldsymbol{u}$ es:

$$\Sigma = \mathrm{Var}(\boldsymbol{u}) = \Omega_u \otimes I_T = \begin{pmatrix} \sigma_{11} I_T & \sigma_{12} I_T \\ \sigma_{21} I_T & \sigma_{22} I_T \end{pmatrix}$$

Su inversa, necesaria para MCG, es: $\Sigma^{-1} = \Omega_u^{-1} \otimes I_T$. Dado que $(A \otimes B)^{-1} = A^{-1} \otimes B^{-1}$

El Estimador SUR y la Simplificación Clave

Fórmula del Estimador MCG (SUR)

El estimador de Mínimos Cuadrados Generalizados (SUR) viene dado por:

$$\widehat{\phi}_{SUR} = (\boldsymbol{Z}^{*'}\Sigma^{-1}\boldsymbol{Z}^{*})^{-1}\boldsymbol{Z}^{*'}\Sigma^{-1}\boldsymbol{X}^{*}$$

Desarrollo del Primer Término: $\boldsymbol{Z}^{*'}\Sigma^{-1}\boldsymbol{Z}^{*}$

Usando las propiedades del producto de Kronecker $(A \otimes B)' = A' \otimes B'$ y $(A \otimes B)(C \otimes D) = (AC \otimes BD)$:

$$\begin{aligned}
\boldsymbol{Z}^{*'}\Sigma^{-1}\boldsymbol{Z}^{*} &= (I_2 \otimes \boldsymbol{Z})'(\Omega_u^{-1} \otimes I_T)(I_2 \otimes \boldsymbol{Z}) \\
&= (I_2' \otimes \boldsymbol{Z}')(\Omega_u^{-1} \otimes I_T)(I_2 \otimes \boldsymbol{Z}) \\
&= (I_2'\Omega_u^{-1} I_2) \otimes (\boldsymbol{Z}' I_T \boldsymbol{Z}) \\
&= \Omega_u^{-1} \otimes (\boldsymbol{Z}'\boldsymbol{Z})
\end{aligned}$$

Sustituyendo en la Fórmula SUR

Invertimos el resultado anterior usando $(A \otimes B)^{-1} = A^{-1} \otimes B^{-1}$:

$$(\boldsymbol{Z}^{*'}\Sigma^{-1}\boldsymbol{Z}^{*})^{-1} = (\Omega_u^{-1} \otimes (\boldsymbol{Z}'\boldsymbol{Z}))^{-1} = (\Omega_u^{-1})^{-1} \otimes (\boldsymbol{Z}'\boldsymbol{Z})^{-1} = \Omega_u \otimes (\boldsymbol{Z}'\boldsymbol{Z})^{-1}$$

Ahora, lo reintroducimos en la fórmula del estimador SUR:

$$\begin{aligned}
\widehat{\phi}_{SUR} &= \left[\Omega_u \otimes (\boldsymbol{Z}'\boldsymbol{Z})^{-1}\right] \boldsymbol{Z}^{*'}\Sigma^{-1}\boldsymbol{X}^{*} \\
&= \left[\Omega_u \otimes (\boldsymbol{Z}'\boldsymbol{Z})^{-1}\right] (I_2 \otimes \boldsymbol{Z})'(\Omega_u^{-1} \otimes I_T)\boldsymbol{X}^{*} \\
&= \left[\Omega_u \otimes (\boldsymbol{Z}'\boldsymbol{Z})^{-1}\right] (I_2 \otimes \boldsymbol{Z}')(\Omega_u^{-1} \otimes I_T)\boldsymbol{X}^{*} \\
&= (\Omega_u I_2 \Omega_u^{-1}) \otimes ((\boldsymbol{Z}'\boldsymbol{Z})^{-1}\boldsymbol{Z}' I_T)\boldsymbol{X}^{*} \\
&= (I_2) \otimes ((\boldsymbol{Z}'\boldsymbol{Z})^{-1}\boldsymbol{Z}')\boldsymbol{X}^{*} \\
&= \begin{pmatrix} (\boldsymbol{Z}'\boldsymbol{Z})^{-1}\boldsymbol{Z}' & \mathbf{0} \\ \mathbf{0} & (\boldsymbol{Z}'\boldsymbol{Z})^{-1}\boldsymbol{Z}' \end{pmatrix} \begin{pmatrix} \boldsymbol{X}_1 \\ \boldsymbol{X}_2 \end{pmatrix}
\end{aligned}$$

Conclusión: Equivalencia Demostrada

Resultado Final

Al realizar la multiplicación de matrices del paso anterior, obtenemos:

$$\widehat{\phi}_{SUR} = \begin{pmatrix} (\boldsymbol{Z}'\boldsymbol{Z})^{-1}\boldsymbol{Z}'\boldsymbol{X}_1 \\ (\boldsymbol{Z}'\boldsymbol{Z})^{-1}\boldsymbol{Z}'\boldsymbol{X}_2 \end{pmatrix}$$

Mismo Estimador

Este resultado es idéntico al vector de estimadores de MCO que construimos en el Paso 2.

$$\widehat{\phi}_{SUR} = \widehat{\phi}_{MCO}$$

La estructura del producto de Kronecker se simplifica completamente debido a que la matriz de regresores $\boldsymbol{Z}$ es la misma en todas las ecuaciones, haciendo que el estimador SUR colapse al estimador MCO aplicado ecuación por ecuación.

Equivalencia de estimadores (mismos Z en todas las ecuaciones)

Por ecuación (MCO)

$$\hat{\theta}_{i,\text{MCO}} = (Z'Z)^{-1}Z'\,\mathbf{y}_i, \qquad i = 1, \ldots, M.$$

Apilado (SUR)

$$\hat{\theta}_{\text{SUR}} = \left(I_M \otimes (Z'Z)^{-1}Z'\right)\mathbf{y}$$

$$\mathbf{y} = \begin{bmatrix} \mathbf{y}_1 \\ \vdots \\ \mathbf{y}_M \end{bmatrix}, \qquad \hat{\theta}_{\text{SUR}} = \begin{bmatrix} \hat{\theta}_{1,\text{MCO}} \\ \vdots \\ \hat{\theta}_{M,\text{MCO}} \end{bmatrix}.$$

Lectura inmediata

- $\hat{\theta}_{\text{SUR}} = \hat{\theta}_{\text{MCO}}$ (coeficientes **idénticos**).
- $\widehat{\mathbf{y}}_i$ y $\hat{u}_i$: **iguales** en MCO y SUR.
- Para inferencia *entre ecuaciones*, usar

$$\widehat{\text{Var}}(\hat{\theta}) = \hat{\Omega}_u \otimes (Z'Z)^{-1}.$$

Idea visual

$$\underbrace{\text{MCO por ecuación}}_{\text{calcula cada } \hat{\theta}_i} + \underbrace{\hat{\Omega}_u}_{\text{correlación entre ecuaciones}}$$

pero con la **covarianza conjunta correcta** para pruebas cruzadas.

Varianzas individuales: iguales en MCO y SUR

Varianza SUR vs MCO - Diagonal

$$\text{Var}\left(\hat{\theta}_{\text{SUR}}\right) = \Omega_u \otimes (Z'Z)^{-1}.$$

Bloque i, i:

$$\text{Var}\left(\hat{\theta}_{i,\text{SUR}}\right) = \omega_{ii}\,(Z'Z)^{-1} = \text{Var}\left(\hat{\theta}_{i,\text{MCO}}\right).$$

Conclusión: *no hay ganancia de eficiencia por ecuación* (mismos errores estándar marginales).

Diferencia clave: covarianzas cruzadas entre ecuaciones

Varianza SUR vs MCO - Fuera de la diagonal

Para $i \neq j$:

$$\text{Cov}\left(\hat{\theta}_{i,\text{SUR}}, \hat{\theta}_{j,\text{SUR}}\right) = \omega_{ij}\,(Z'Z)^{-1} \quad (\neq 0 \text{ si } \omega_{ij} \neq 0).$$

Estas covarianzas **no** aparecen si hacés MCO y *suponés independencia* entre ecuaciones.

Implicancia: cualquier **prueba conjunta** que mezcle parámetros de distintas ecuaciones debe usar

$$\widehat{\text{Var}}(\hat{\theta}) = \hat{\Omega}_u \otimes (Z'Z)^{-1}$$

para ser eficiente y con nivel correcto.

Pruebas conjuntas: Wald eficiente

Prueba de Wald

$$W = (R\hat{\theta} - r)' \left[R\,\widehat{\mathrm{Var}}(\hat{\theta})\,R' \right]^{-1} (R\hat{\theta} - r).$$

Con mismos Z: como $\hat{\theta}_{\mathrm{SUR}} = \hat{\theta}_{\mathrm{MCO}}$, si usás $\widehat{\mathrm{Var}}(\hat{\theta}) = \hat{\Omega}_u \otimes (Z'Z)^{-1}$, el estadístico Wald es **idéntico** al de SUR factible.

Mala práctica: ignorar las covarianzas cruzadas (usar sólo bloques diagonales) $\Rightarrow$ varianzas infladas $\Rightarrow$ menor potencia.

Mini-ejemplo: probar $\theta_{1,k} = \theta_{2,k}$

Sea $d = \hat{\theta}_{1,k} - \hat{\theta}_{2,k}$. Entonces

$$\mathrm{Var}(d) = \left(\omega_{11} + \omega_{22} - 2\omega_{12}\right) \cdot \left[(Z'Z)^{-1}\right]_{kk}.$$

- **Correcto (SUR o MCO + varianza conjunta):** incluye $-2\omega_{12} \Rightarrow$ varianza menor $\Rightarrow$ test más potente.
- **Incorrecto (MCO ingenuo):** usa $(\omega_{11} + \omega_{22})[(Z'Z)^{-1}]_{kk}$ (omite ω_{12}) $\Rightarrow$ varianza inflada.

$$W = \frac{d^2}{\widehat{\mathrm{Var}}(d)} \sim \chi^2_1 \quad \text{(o } F \text{ con gl).}$$

¿Cuándo SUR mejora también los coeficientes?

Distintor regresores diferencia entre SUR y MCO

Cuando los regresores **no** son idénticos entre ecuaciones (columnas distintas, rezagos distintos, instrumentos, etc.).

$$Z^* \neq I_M \otimes Z \;\Rightarrow\; \hat{\theta}_{\text{SUR}} \neq \hat{\theta}_{\text{MCO}},$$

y GLS aprovecha Ω_u para reducir varianzas *por ecuación*.

Resumen

- El VAR puede estimarse por MCO ecuación por ecuación de forma consistente.
- Pero si los errores están correlacionados entre ecuaciones, MCO puede perder eficiencia en las pruebas conjuntas.
- El método SUR aprovecha esa correlación y la matriz de varianza que contempla las correlaciones entre los errores de las ecuaciones .
- La ganancia es mayor cuando hay fuerte correlación contemporánea y muestras pequeñas.